Modelo preditivo

IBOVESPA

UTILIZANDO MACHINE LEARNING

Start

INTEGRANTES

10 DTAT

Nome	RM
Rhômulo Mourão	365205
Elecides Junior	366315
Rafael Victor Pereira	366441
Anderson Correia Balbino	365550
Gabriel Maciel dos Santos	365687

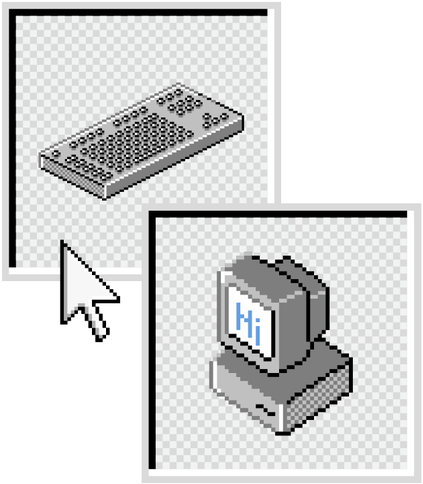

DEFININDO O OBJETIVO

O objetivo central do projeto é desenvolver um modelo de Machine Learning robusto, utilizando dados históricos do IBOVESPA, para prever a tendência direcional do índice (Alta ou Baixa) no dia seguinte.

Meta de Performance: A acurácia mínima definida para o sucesso do modelo foi de **75% no conjunto de teste** para validar a capacidade preditiva do sistema.

CONTEXTO E METODOLOGIAS

Trabalhamos com dados financeiros, que são intrinsecamente séries temporais. Isso exige uma abordagem de Classificação Binária (0 para Desceu, 1 para Subiu) e o tratamento rigoroso contra o vazamento de dados dentro do modelo escolhido.

Optamos por algoritmos baseados em **árvores** ou **natureza não-paramétrica** nos modelos.

FERRAMENTAS PRINCIPAIS E DATASETS

Dataset: dados históricos Ibovespa entre 2015 e 2025

br.investing.com/indices/bovespa-historical-data

Scikit-learn

Pandas / Numpy

Random Forest

KNeighbors

XGBoost

TRATAMENTO E LIMPEZA DOS DADOS

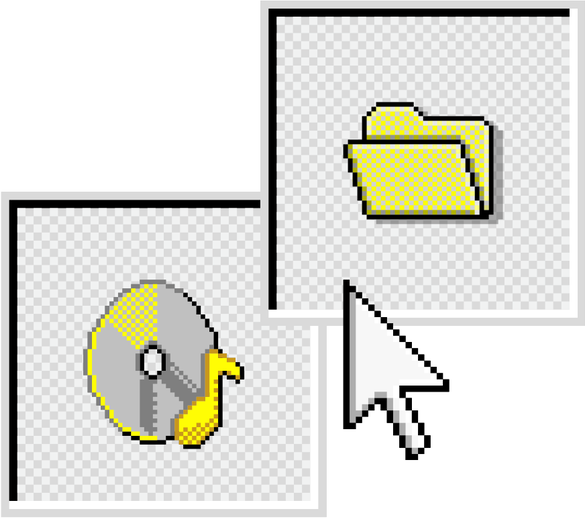

O primeiro desafio a ser enfrentado para uma boa análise é a limpeza e preparação dos dados, que se deu da seguinte forma:

Datas: Conversão da coluna de data para o tipo *datetime*.

Numéricos: Remoção de separadores de milhares e conversão de colunas como *Último*, *Abertura* e *Vol*. para o tipo *float*.

Tratamento de *NaN*: Valores nulos (calculados por janelas móveis) foram tratados por *fillNa* ou eliminação de linhas, garantindo a integridade dos dados.

ANÁLISE EXPLORATÓRIA (EDA)

Imagens geradas em Notebook Python

TENDÊNCIA E VOLATILIDADE

Observa-se tendência de alta no longo prazo, com períodos de maior volatilidade.

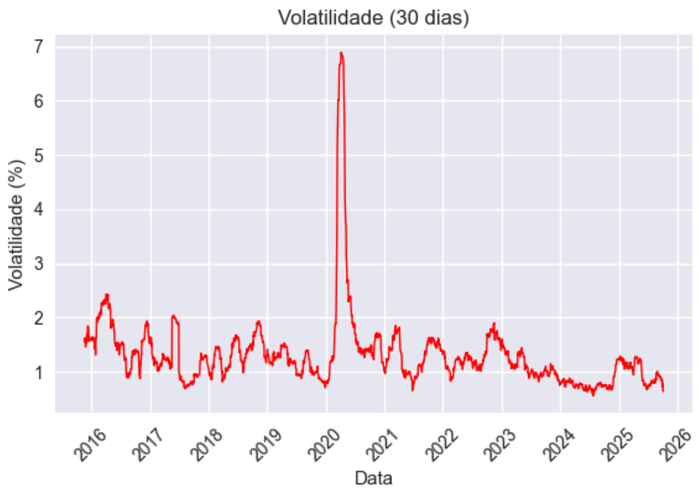

Picos de volatilidade coincidem com eventos significativos de mercado.

ANÁLISE EXPLORATÓRIA (EDA)

Imagens geradas em Notebook Python

DISTRIBUIÇÃO E CORRELAÇÕES

Alta correlação entre preços.
Correlação mais baixa entre preços e Volume/Variação%

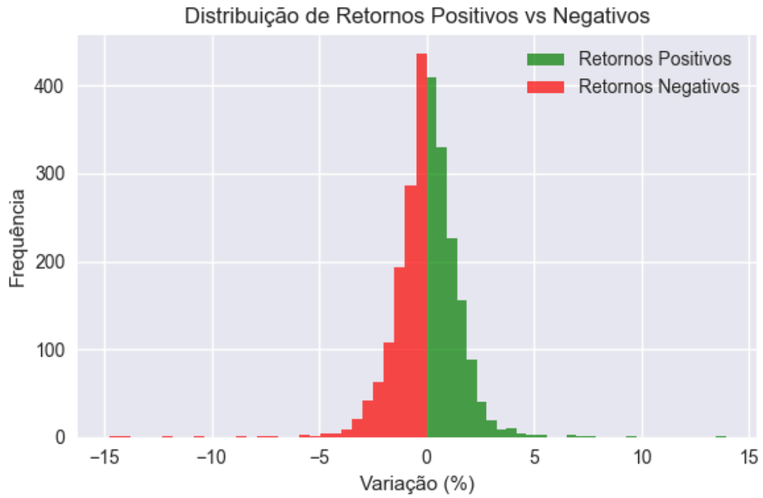

Distribuição com levemente mais dias positivos (52.5%) que negativos (47.3%).

FEATURE ENGINEERING

Médias Móveis em diferentes horizontes

Criação features que capturem informações de tendência, momento, volatilidade e padrões passados:

- Retornos de 1 e 5 dias,
- Médias Móveis Simples de 5 e 20 dias
- Posição do Preço vs médial móvel de 20.dias.
- Volatilidade de 10 dias.
- Índice de Força Relativa de 14 dias.
- Convergência/Divergência da Média Móvel.
- Direção do Dia Anterior.
- Posição do Preço vs média móvel de 50 dias.

PREPARAÇÃO PARA MODELAGEM

Definição de TARGET e Divisão dos Dados

Variável Alvo (Target): Definida como 1 se o retorno percentual do dia seguinte for maior que 0.5%, e 0 caso contrário.

Target Desbalanceado! Apenas 35.5% dos dias tiveram alta > 0.5% no período analisado.

Divisão Treino/Teste: Dados de treino até 30 dias antes do final; últimos 30 dias para teste (abordagem temporal).

Escalonamento: Features normalizadas usando StandardScaler.

XGBOOST

MODELO CLASSIFICADOR

Treinamento e Resultados:

Escolhido por sua performance em dados tabulares e pela capacidade de lidar com relações complexas.

Tratamento do Desbalanceamento e Threshold: Uso do parâmetro *class_pos_weight* no treino e obtenção de probabilidade (0.112), otimizado no conjunto de teste para maximizar F1-Score.

RANDOM FOREST

MODELO DE ENSEMBLE LEARNING

Utilizamos o Random Forest Classifier, um modelo de *ensemble learning* robusto, baseado em múltiplas árvores de decisão.
Os hiperparâmetros foram ajustados com *GridSearchCV* para melhorar o desempenho do modelo.

O limiar de probabilidade (*Threshold*) foi ajustado para 0.216, buscando maximizar o *F1-Score*.

Os Resultados obtidos no teste foram:

Acurácia: 50% (não atingiu o objetivo de 75%)
Precisão (Classe1 - Alta > 0.5%): 39%.
Recall: 90%.
F1-Score: 55%

Validação cruzada (Treino):

Acurácia média: 65.41%

Matriz de confusão:
Representa a comparação entre previsões corretas e incorretas do modelo.

```
[[19  1]
 [10  0]]
```

COMPARAÇÃO DE MODELOS E IMPORTÂNCIA DAS FEATURES

- **Modelo Adicional:** *K-Nearest Neighbors* também testado (via *RandomizedSearchCV*), Acurácia no Teste: 56.67% (não previu nenhuma alta).

- **Comparativo de Acurácia no Teste**: Gráfico de barras mostrando XGBoost (76.67%) vs RF (63.33%) vs KNN (56.67%) vs Meta (75%). [Gráfico 1].

- **Melhor Modelo**: **XGBoost foi o único a atingir a meta no conjunto de teste.**

Vide a importância das Features (XGBoost vs RF)[Gráficos 2 e 3].
Features como Médias Móveis de 5 e 20 dias(MA_5, MA_20), Retornos de 1 e 5 dias (Retorno_1d, Retorno_5d), preço vs média móvel de 5 dias (Price_vs_EMA50) e média móvel de Convergência e Divergência (MACD) aparecem como importantes em ambos gráficos, indicando sua relevância.

Comparativo de Acurácia no Teste

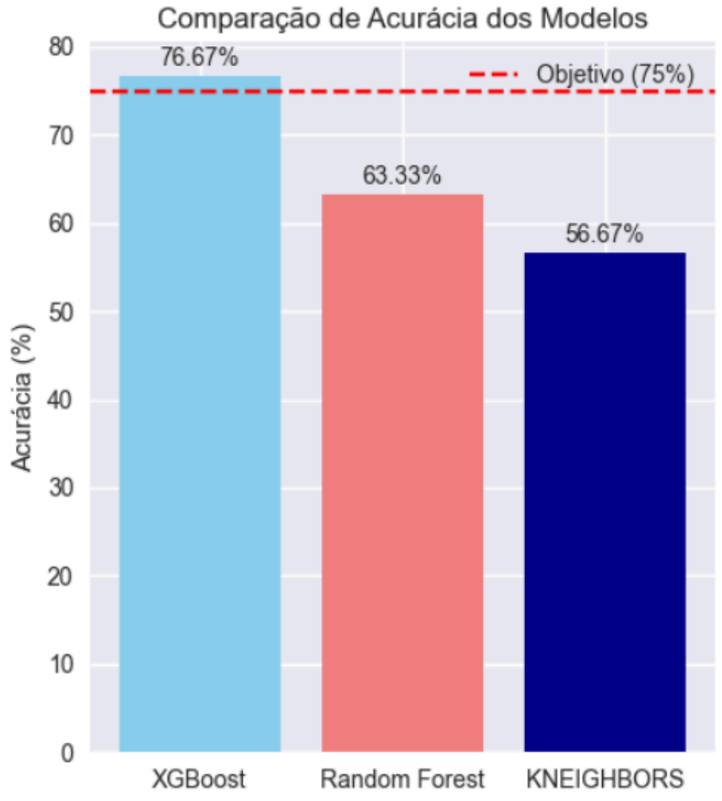

Gráfico 1

Importância das Features

Gráfico 2

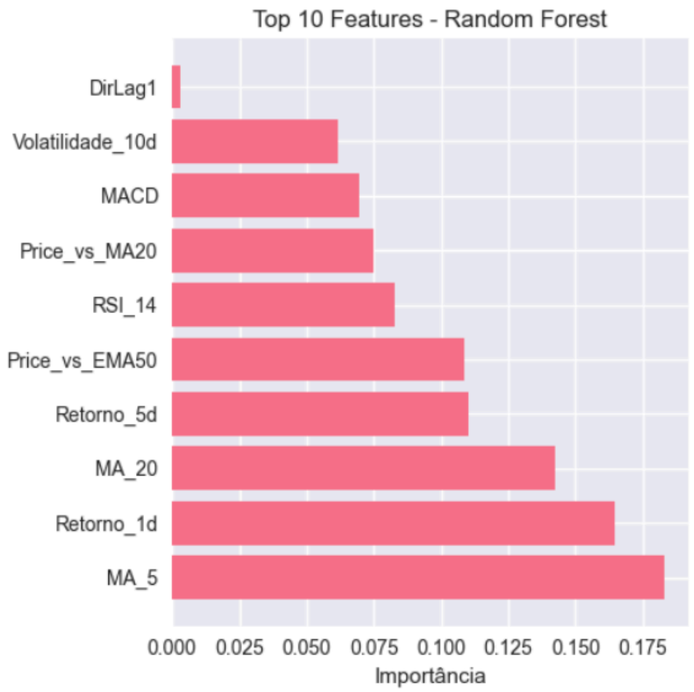

Gráfico 3

JUSTIFICATIVA TÉCNICA

- O modelo XGBoost atingiu 76,67% de acurácia no conjunto de teste, cumprindo o objetivo definido de superar 75%.
- O modelo fornece um sinal diário sobre a probabilidade de alta no dia seguinte, apoiando a análise de tendência e decisões de investimento.
- O XGBoost apresentou o melhor desempenho no conjunto de teste sendo mais adequado para capturar não-linearidades do que RF e KNN.
- Foram utilizadas features que incorporam histórico temporal:
  - Lags (Retorno_1d, Retorno_5d)
  - Médias móveis e indicadores técnicos (MA, EMA, RSI, MACD)
- A natureza sequencial foi preservada com:
  - Divisão treino/teste temporal
  - Validação cruzada com TimeSeriesSplit

TRADE-OFFS

- A otimização do threshold ocorreu diretamente no teste, o que pode inflar a acurácia devido ao risco de *data leakage*.
- A diferença entre a validação cruzada (aprox. 60%–65%) e o desempenho no teste (76,67%) indica impacto relevante do threshold e possível sobreajuste ao período testado.
- Hiperparâmetros de regularização ajudaram a conter overfitting, mas a generalização ainda pode ser aprimorada.

CONCLUSÃO

RESULTADO PRINCIPAL: XGBOOST

Características: 76.67% ACURÁCIA | 80% RECALL | 62% PRECISÃO

Modelo melhor para identificação de altas (Recall) do que evitar falsos positivos (Precisão)

Features Relevantes: MÉDIAS MÓVEIS | MACD | RSI + TRESHOLD OTIMIZADO

Destaque principal para indicadores a curto prazo e momentum

Otimizações e melhorias: DADOS EXTERNOS | MODELOS COMPLEXOS | SÉRIES TEMPORAIS