Análise das variáveis da PNAD COVID (JUNHO,JULHO,AGOSTO)

Em [2]:
```
import pandas as pd import numpy as np import matplotlib.pyplot as plt import se
avisos . filtraravisos ( 'ignorar' )

plt.style.use ( ' seaborn-v0_8-darkgrid' ) sns.set_palette ( " husl " ) rcParams
```

Em [3]:
```
Golpe_junho  =  r "C:\Usuários\gabri\Documentos\projeto_pnad\PNAD_Junho.csv"
caminho_julho  =  r "C:\Usuários\gabri\Documentos\projeto_pnad\PNAD_Julho.csv"
caminho_agosto  =  r "C:\Usuários\gabri\Documentos\projeto_pnad\PNAD_Agosto.csv"


df_junho  =  pd . read_csv ( caminho_junho ,  sep = "," ,  encoding = "latin1" )
df_julho  =  pd . read_csv ( caminho_julho ,  sep = "," ,  encoding = "latin1" )
df_agosto  =  pd . read_csv ( caminho_agosto ,  sep = "," ,  encoding = "latin1"

# Adicionar coluna de mês
df_junho [ "mes" ]  =  "Junho"
df_julho [ "mes" ]  =  "Julho"
df_agosto [ "mes" ]  =  "Agosto"

df  =  pd . concat ([ df_junho ,  df_julho ,  df_agosto ],  ignore_index = True

print ( "Formato da base unificada:" ,  df . shape )
print ( "Colunas disponíveis:" ,  df . columns . tolist ())
df . cabeça ()
```

```
---------------------------------------------------------------------------
NameError                                 Traceback (última chamada mais recent
e)
 Cell In[3] , linha 6       2 caminho_julho = r " C: \ Users \ gabri \ Documents
\ projeto_pnad \ PNAD_Julho.csv "       3 caminho_agosto = r " C: \ Users \ gabri
\ Documents \ projeto_pnad \ PNAD_Agosto.csv " ----> 6 df_junho = pd.read_csv( ca
minho_junho , sep= " , " , encoding= " latin1 " )
       7 df_julho = pd.read_csv(caminho_julho, sep= " , " , encoding= " latin1 "
)
       8 df_agosto = pd.read_csv(caminho_agosto, sep= " , " , codificação = " lat
in1 " )




NameError : nome 'caminho_junho' não está definido
```

Em [4]:
```
# Dicionário
descricao_variaveis  =  {
```

```
    "A005" :  "Escolaridade" ,
    "C001" :  "Situação de trabalho na semana" ,
    "C013" :  "Modalidade de trabalho (home office)" ,
    "C011A12" :  "Renda do trabalho" ,
    "B0011" :  "Febre" ,
    "B0013" :  "Dor de garganta" ,
    "B0014" :  "Dificuldade para respirar" ,
    "B0019" :  "Perda de olfato ou paladar" ,
    "B0015" :  "Dor de cabeça" ,
    "B0018" :  "Diarreia" ,
    "B0012" :  "Tosse" ,
    "B0016" :  "Dor no peito" ,
    "B0017" :  "Náusea ou vômito" ,
    "B00111" :  "Outro sintoma"
}

variaveis_trabalho  =  [ "C001" ,  "C013" ,  "C011A12" ]
variaveis_escolaridade  =  [ "A005" ]
variaveis_sintomas  =  [
    "B0011" , "B0012" , "B0013" , "B0014" ,
    "B0015" , "B0016" , "B0017" , "B0018" , "B0019" , "B00111"
]

variaveis_usadas  =  list ( set ( variaveis_trabalho  +  variaveis_escolaridade

df_f  =  df [ df [ "Variavel" ] . isin ( variáveis_usadas )] . copy ()
print ( "Formato do df_f (apenas variáveis relevantes):" ,  df_f . shape )
df_f . cabeça ()
```

```
Formato do df_f (apenas variáveis relevantes): (16127384, 10)
```

Saída[4…

	UF	CAPITAL	RM_RIDE	Estrato	UPA	pose	Ano_2020	Variável	Vale
6481590	11	11.0	NaN	1110011	110015970	1114	1	A005	
6481591	11	11.0	NaN	1110011	110015970	1123	1	A005	
6481592	11	11.0	NaN	1110011	110015970	1112	1	A005	
6481593	11	11.0	NaN	1110011	110015970	1112	1	A005	
6481594	11	11.0	NaN	1110011	110015970	1126	1	A005	

Trabalho (presencial, bico) e Home Office

Em [5]:

```
# Dicionário - C001
categorias_trabalho  =  {
    1.0 :  "Trabalhou" ,
    2.0 :  "Não trabalhou, mas tinha trabalho" ,
    3.0 :  "Não trabalhou e não tinha trabalho"
}

df_trabalho  =  df_f [ df_f [ "Variavel" ]  ==  "C001" ] . copy ()
df_trabalho [ "Categoria" ]  =  df_trabalho [ "Valor" ] . mapa ( categorias_trab

freq_trabalho_total  =  df_trabalho [ "Categoria" ] . valor_contagens () . índic
```

```
plt . figura ( figsize = ( 10 ,  5 ))
sns . barplot ( x = freq_trabalho_total . index ,  y = freq_trabalho_total . val
plt . title ( "Situação de trabalho — total (Junho, Julho e Agosto)" ,  fontsize
plt . xlabel ( "Situação de trabalho" )
plt . ylabel ( "Quantidade de pessoas" )
plt . xticks ( rotação = 20 )
plt . tight_layout ()
plt . mostrar ()
```

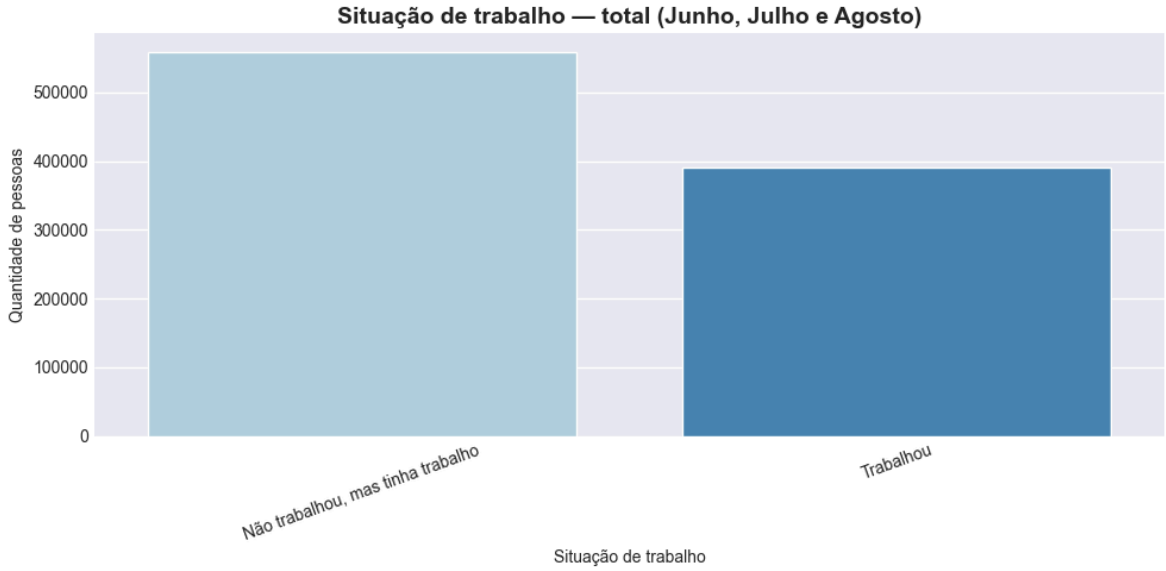

Em [6]:

```
# Comparando os meses
freq_trabalho_mes  =  (
    df_trabalho . groupby ([ "mes" ,  "Categoria" ])
    . size ()
    . reset_index ( name = "Quantidade" )
)

plt . figura ( figsize = ( 12 ,  6 ))
sns . barplot (
    data = freq_trabalho_mes ,
    x = "Categoria" ,
    y = "Quantidade" ,
    hue = "mes" ,
    paleta = "Blues"
)
plt . title ( "Situação de trabalho — comparação entre meses" ,  fontsize = 14 ,
plt . xlabel ( "Situação de trabalho" )
plt . ylabel ( "Quantidade de pessoas" )
plt . xticks ( rotação = 20 )
plt . legenda ( título = "Mês" )
plt . tight_layout ()
plt . mostrar ()
```

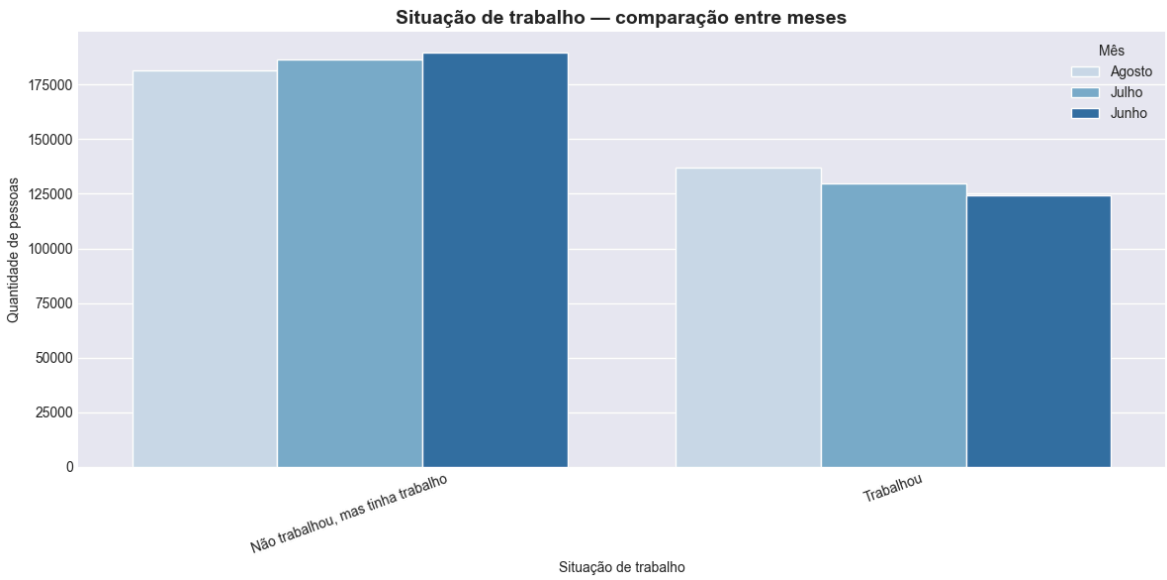

da para ver um pequeno aumento de pessoas sem trabalho ou afastadas, o que ajuda a entender a dinâmica da pandemia no mercado

Em [7]:
```
# Home office C013 (geral)
categorias_homeoffice = {
    1.0 : "Trabalho remoto" ,
    2.0 : "Presencial"
}

df_home = df_f [ df_f [ "Variavel" ] == "C013" ] . copy ()
df_home [ "Categoria" ] = df_home [ "Valor" ] . map ( categorias_homeoffice )

freq_home_total = df_home [ "Categoria" ] . value_counts () . sort_index ()

plt . figura ( figsize = ( 10 , 5 ))
sns . barplot ( x = freq_home_total . index , y = freq_home_total . valores ,
plt . title ( "Modalidade de trabalho – total (Junho, Julho e Agosto)" , fontsi
plt . xlabel ( "Modalidade" )
plt . ylabel ( "Quantidade de pessoas" )
plt . tight_layout ()
plt . mostrar ()
```

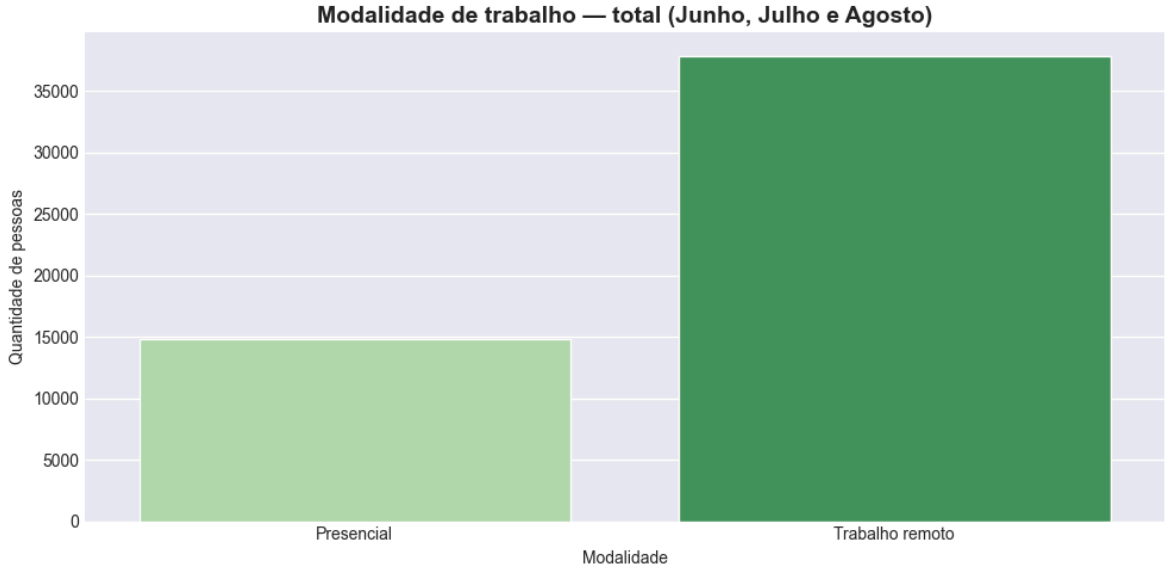

Em [8]:
```
# Comparando 3 meses de Home
freq_home_mes = (
    df_home . groupby ([ "mes" , "Categoria" ])
    . size ()
    . reset_index ( name = "Quantidade" )
)

plt . figura ( figsize = ( 12 , 6 ))
sns . barplot (
    data = freq_home_mes ,
    x = "Categoria" ,
    y = "Quantidade" ,
    hue = "mes" ,
    paleta = "Verdes"
)
plt . title ( "Modalidade de trabalho — comparação entre meses" , fontsize = 14
plt . xlabel ( "Modalidade" )
plt . ylabel ( "Quantidade de pessoas" )
plt . tight_layout ()
plt . mostrar ()
```

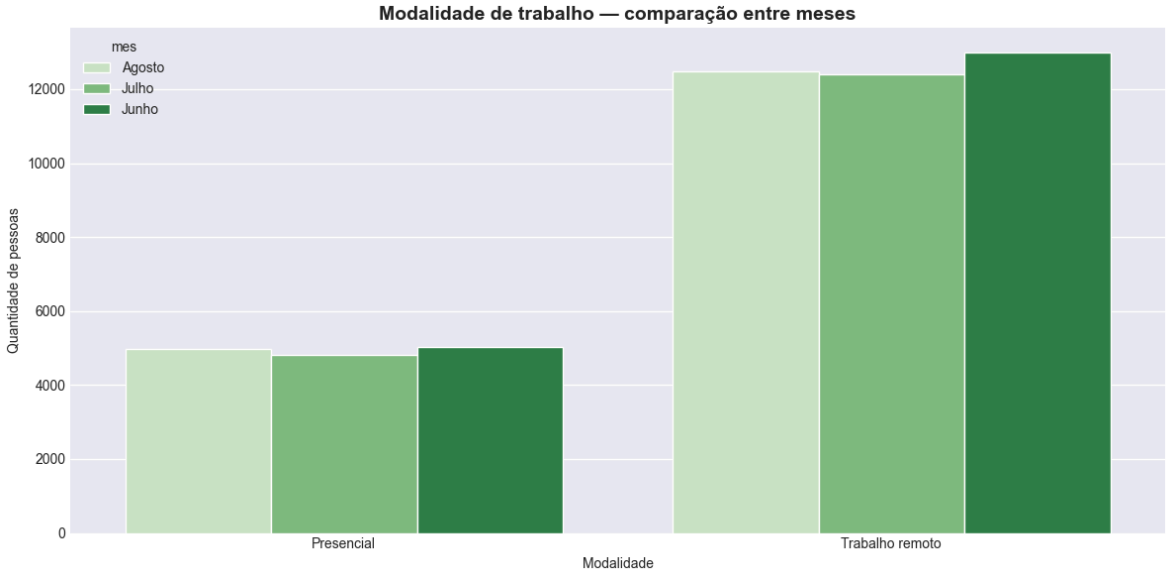

Renda

Em [9]:
```
df_renda = df_f [ df_f [ "Variavel" ] == "C011A12" ] . copiar ()

df_renda [ "Valor" ] = pd . to_numeric ( df_renda [ "Valor" ], erros = "coagi
df_renda = df_renda . dropna ( subconjunto = [ "Valor" ])

print ( "Estatísticas descritivas da renda do trabalho:" )
print ( df_renda [ "Valor" ] . descrever ())
```

```
Estatísticas descritivas da renda do trabalho:
contagem 420247.000000
média 1943,645359
padrão 2796,707378
mínimo 0,000000
25% 800.000000
50% 1200.000000
75% 2000.000000
máximo 200000.000000
Nome: Valor, tipo de dados: float64
```

Em [10]:

```
# Por mês
plt . figura ( figsize = ( 12 ,  6 ))
sns . barplot ( data = df_renda ,  x = "mes" ,  y = "Valor" ,  paleta = "pastel"
plt . title ( "Renda de trabalho por mês" ,  fontsize = 14 ,  fontweight = "bold
plt . xlabel ( "Mês" )
plt . ylabel ( "Renda do trabalho" )
plt . tight_layout ()
plt . mostrar ()
```

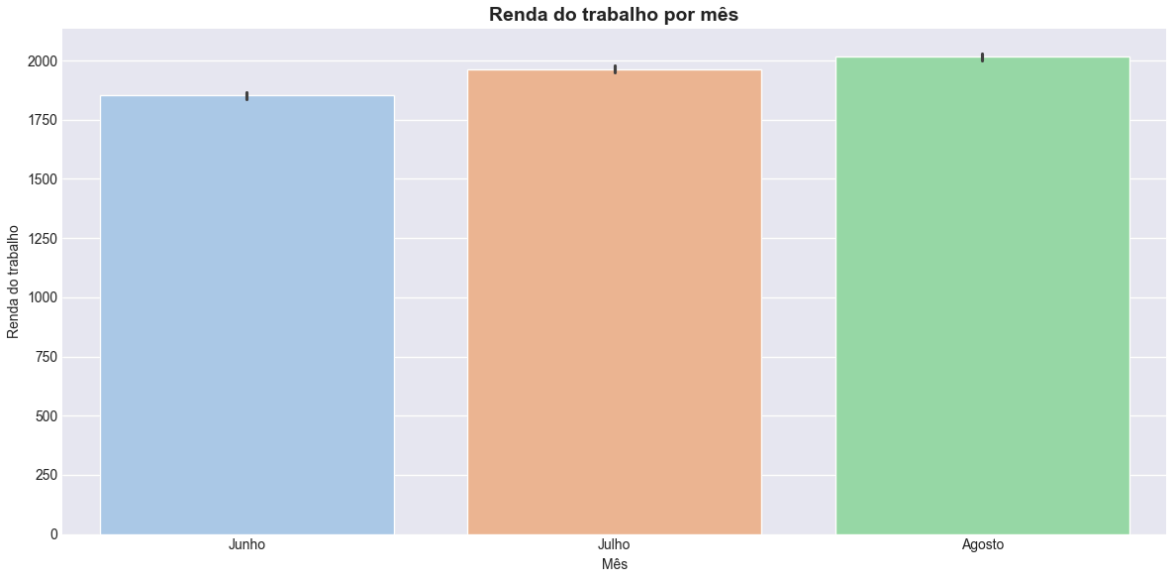

Em [11]:

```
# Home Office - C013
categorias_homeoffice  =  {
    1.0 :  "Trabalho remoto" ,
    2.0 :  "Presencial"
}

df_home  =  df_f [ df_f [ "Variavel" ]  ==  "C013" ] . copy ()
df_home [ "HomeOffice" ]  =  df_home [ "Valor" ] . map ( categorias_homeoffice )

# Escolaridade A005
categorias_escolaridade  =  {
    1.0 :  "Sem instrução" ,
    2.0 :  "Fundamental incompleto" ,
    3.0 :  "Fundamental completo" ,
    4.0 :  "Médio incompleto" ,
    5.0 :  "Médio completo" ,
    6.0 :  "Superior incompleto" ,
    7.0 :  "Superior completo" ,
    8.0 :  "Pós-graduação"
}
```

```
df_esc = df_f [ df_f [ "Variavel" ] == "A005" ] . copy ()
df_esc [ "Escolaridade" ] = df_esc [ "Valor" ] . mapa ( categorias_escolaridad
```

Em [12]:

```
dist_esc = df_esc [ "Escolaridade" ] . value_counts ( normalize = True ) .sort
dist_home = df_home [ "HomeOffice" ] . value_counts ( normalize = True ) .sort

tabela_cruzada = pd . DataFrame ({
    "Proporção Escolaridade (%)" : dist_esc * 100 ,
    "Proporção Home Office (%)" : dist_home .mean ( ) * 100  # média geral
})

print ( "Tabela cruzada aproximada (proporções):" )
tabela_cruzada
```

```
Tabela cruzada aproximada (proporções):
```

Saída[1…

Escolaridade	Proporção Escolaridade (%)	Proporção Home Office (%)
Fundamental completo	6,647389	50,0
Fundamental incompleto	33,677588	50,0
completo	22.356930	50,0
casa incompleto	9,381174	50,0
Pós-graduação	2,574578	50,0
Sem	10,759612	50,0
Superior completo	9,408259	50,0
Superior incompleto	5,194469	50,0

Em [13]:

```
# Proporção de home office por escolaridade /aprox
prop_home_por_esc = (
    df_home [ "HomeOffice" ] . value_counts ( normalize = True ) * 100
)

plt . figura ( figsize = ( 10 , 5 ))
sns . barplot (
    x = prop_home_por_esc . index ,
    y = prop_home_por_esc . valores ,
    paleta = "Verdes"
)
plt . title ( "Proporção de Home Office — visão geral" , fontsize = 14 , fontw
plt . xlabel ( "Categoria" )
plt . ylabel ( "Proporção (%)" )
plt . tight_layout ()
plt . mostrar ()
```

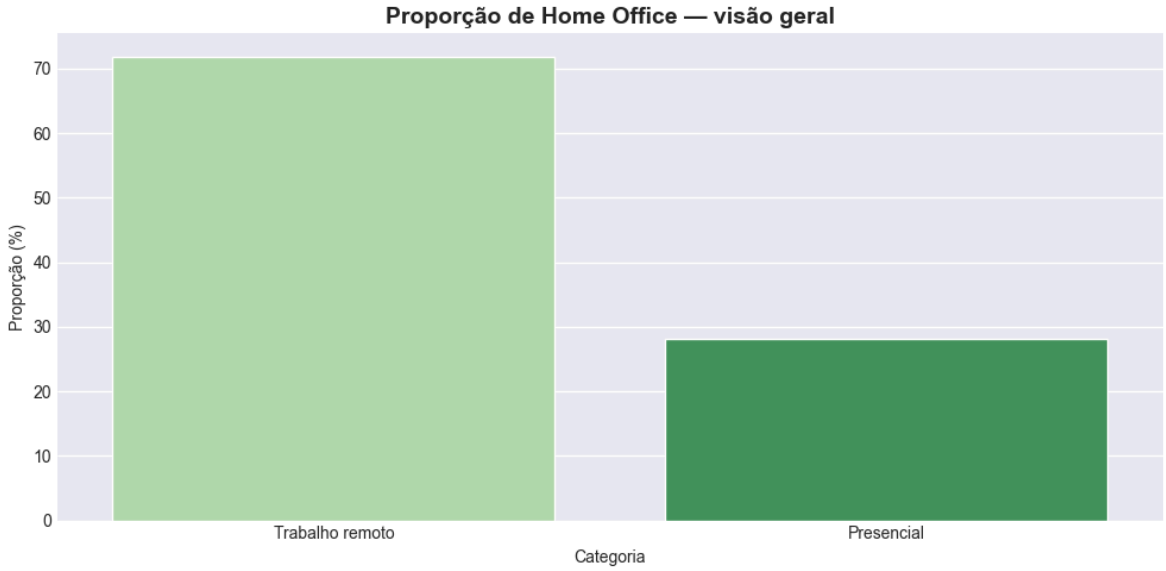

Trazendo a renda por escolaridade

Em [24]:
```
# Criar ID por pessoa
df_f [ "ID_PESSOA" ]  =  (
    df_f [ "UPA" ] . astype ( str )  +  "_"  +
    df_f [ "Estrato" ] . astype ( str )  +  "_"  +
    df_f [ "posest" ] . astype ( str )
)
```

Em [29]:
```
# Filtrar apenas renda e escolaridade
df_sub  =  df_f [ df_f [ "Variavel" ] . isin ([ "C011A12" ,  "A005" ])] . copiar



df_wide  =  df_sub.pivot_table ( index = "ID_PESSOA" , columns = "Variavel" , va





df_wide [ " C011A12" ]  =  pd.to_numeric ( df_wide [ " C011A12" ], errors = "coe


df_largo  =  df_largo . dropna ( subset = [ "C011A12" ,  "Escolaridade" ])

renda_por_esc  =  (
    df_wide . groupby ( "Escolaridade" )[ "C011A12" ]
    . median ()
    . sort_index ()
)

plt . figura ( figsize = ( 12 ,  6 ))
sns . barplot ( x = renda_por_esc . index ,  y = renda_por_esc . valores ,  pale
plt . title ( "Renda média por escolaridade" ,  fontsize = 14 ,  fontweight = "b
plt . xlabel ( "Escolaridade" )
plt . ylabel ( "Renda mediana (R$)" )
plt . xticks ( rotação = 45 )
plt . tight_layout ()
plt . mostrar ()
```

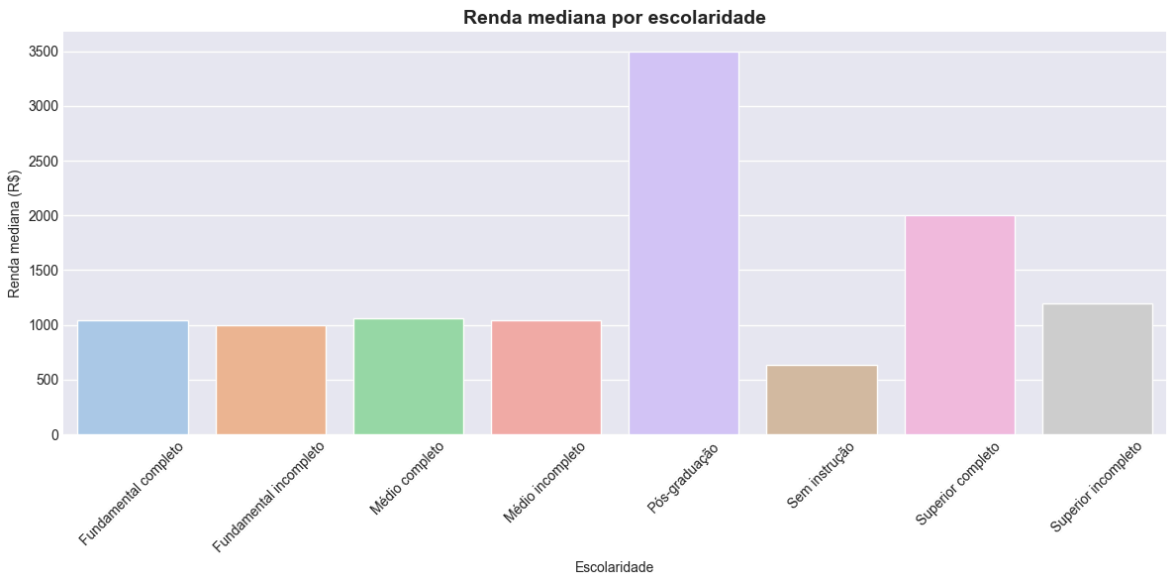

A criação do ID_PESSOA a partir da UPA, Estrato e posest permitiu vincular corretamente as variáveis da PNAD, e foi possível cruzar renda e escolaridade de forma precisa

Renda x Situação de trabalho

C001 → elaborado / não elaborado / desenvolvido

Em [30]:
```
df_sub  =  df_f [ df_f [ "Variavel" ] . isin ([ "C011A12" ,  "C001" ])] . copy (

df_wide  =  df_sub.pivot_table ( index = "ID_PESSOA" , columns = "Variavel" , va

df_wide [ "C011A12" ]  =  pd.to_numeric ( df_wide [ " C011A12" ], errors = " coe

df_largo  =  df_largo . dropna ( subconjunto = [ "C011A12" ,  "Trabalho" ])
```

Em [32]:
```
# Renda mediana por situação de trabalho
renda_trabalho  =  (
    df_wide . groupby ( "Trabalho" )[ "C011A12" ]
    . median ()
    . sort_values ()
)

plt . figura ( figsize = ( 12 ,  6 ))
sns . barplot ( x = renda_trabalho . index ,  y = renda_trabalho . valores ,  pa
plt . title ( "Renda mediana por situação de trabalho" ,  fontsize = 14 ,  fontw
plt . xlabel ( "Situação de trabalho" )
plt . ylabel ( "Renda mediana (R$)" )
plt . xticks ( rotação = 45 )
plt . tight_layout ()
plt . mostrar ()
```

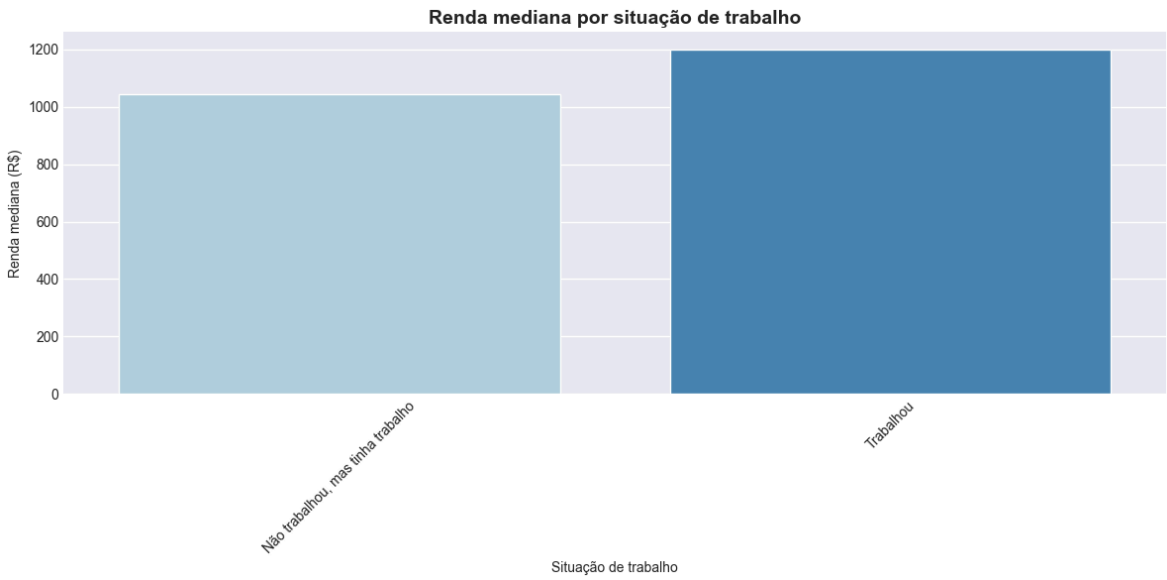

quem trabalhou possui maior renda, afastados e desocupados concentram valores menores

--possivel análise de grupo que contraiu o vírus

Página inicial x Renda

Em [33]:
```
df_sub  =  df_f [ df_f [ "Variavel" ] . isin ([ "C011A12" ,  "C013" ])] . copy (

df_wide  =  df_sub.pivot_table ( index = "ID_PESSOA" , columns = "Variavel" , va




df_wide [ " C011A12" ]  =  pd.to_numeric ( df_wide [ " C011A12" ], errors = "coe


df_wide  =  df_wide.dropna ( subset = [ " C011A12" , " HomeOffice" ])
```

Em [34]:
```
renda_home  =  (
    df_wide . groupby ( "HomeOffice" )[ "C011A12" ]
    . median ()
    . sort_values ()
)

plt . figura ( figsize = ( 12 ,  6 ))
sns . barplot ( x = renda_home . index ,  y = renda_home . valores ,  paleta = "
plt . title ( "Renda mediana por modalidade de trabalho (home office)" ,  fontsi
plt . xlabel ( "Escritório doméstico" )
plt . ylabel ( "Renda mediana (R$)" )
plt . xticks ( rotação = 45 )
plt . tight_layout ()
plt . mostrar ()
```

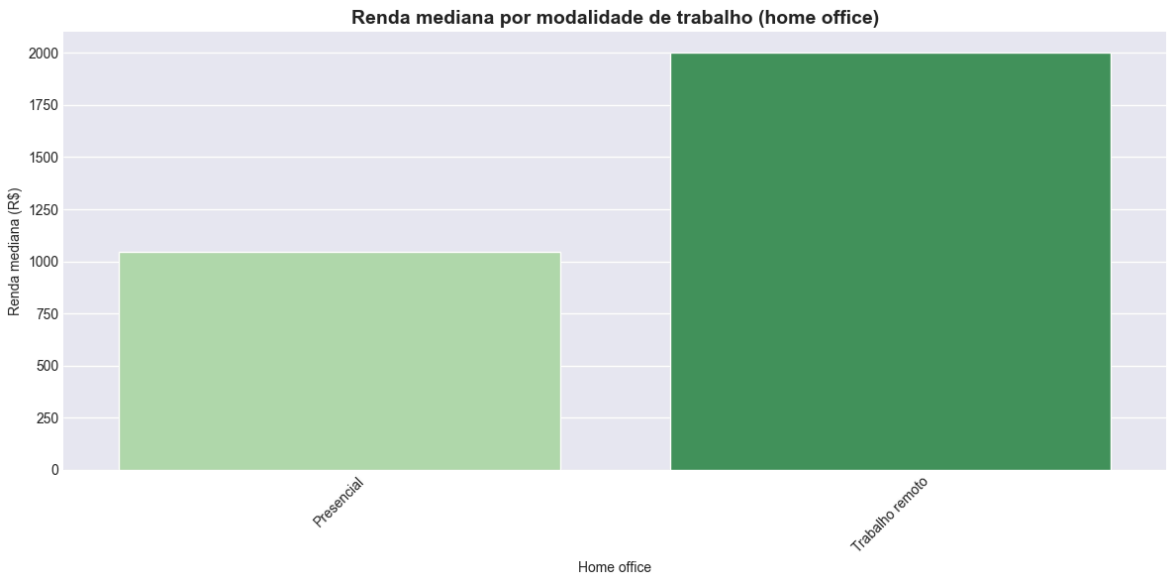

quem faz Home, apresenta maior renda, ocupando posição onde desativar mais qualificação

Evolução dos 3 meses (Junho, Julho e Agosto)

Em [36]:
```
# Situação de trabalho
df_trab = df_f [ df_f [ "Variavel" ] == "C001" ] . copy ()
df_trab [ "Trabalho" ] = df_trab [ "Valor" ] . astype ( float ) . mapa ( categ

freq_trab_mes = (
    df_trab . groupby ([ "mes" , "Trabalho" ])
    . size ()
    . reset_index ( name = "Quantidade" )
)

plt . figura ( figsize = ( 12 , 6 ))
sns . lineplot (
    data = freq_trab_mes ,
    x = "mes" ,
    y = "Quantidade" ,
    hue = "Trabalho" ,
    marcador = "o"
)
plt . title ( "Evolução da situação de trabalho (JUNHO,JULHO,AGOSTO)" , fontsiz
plt . tight_layout ()
plt . mostrar ()
```

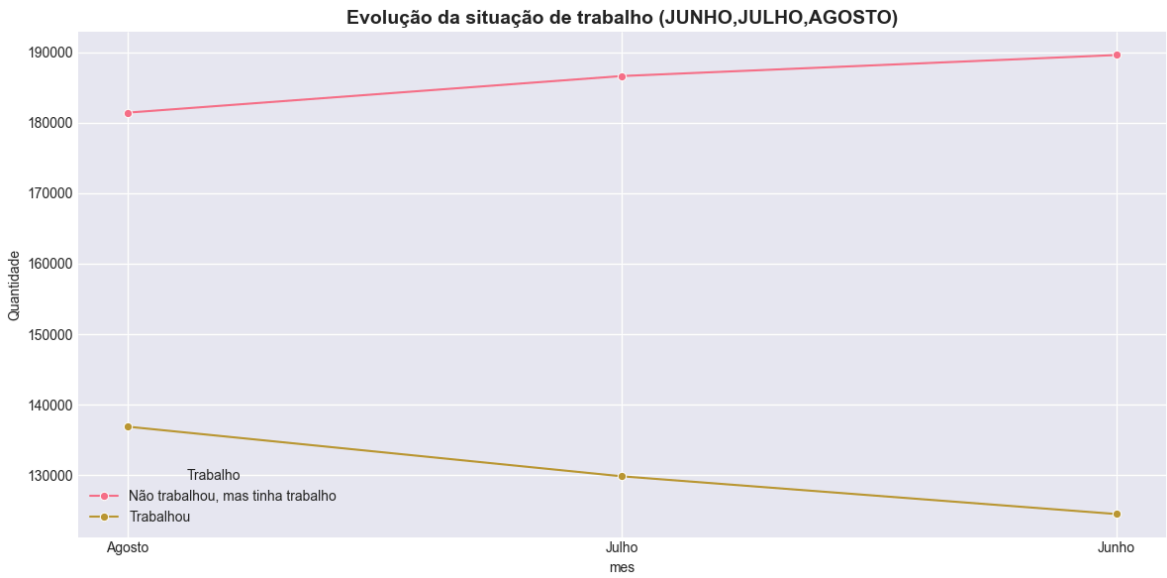

Em [37]:

```
# Home Office
df_home  =  df_f [ df_f [ "Variavel" ]  ==  "C013" ] . copy ()
df_home [ "HomeOffice" ]  =  df_home [ "Valor" ] . astype ( float ) . map ( cate

freq_home_mes  =  (
    df_home . groupby ([ "mes" ,  "HomeOffice" ])
    . size ()
    . reset_index ( name = "Quantidade" )
)

plt . figura ( figsize = ( 12 ,  6 ))
sns . lineplot (
    data = freq_home_mes ,
    x = "mes" ,
    y = "Quantidade" ,
    hue = "HomeOffice" ,
    marcador = "o" ,
    paleta = "Verdes"
)
plt . title ( "Evolução do home office (JUNHO,JULHO,AGOSTO)" ,  fontsize = 14 ,
plt . tight_layout ()
plt . mostrar ()
```

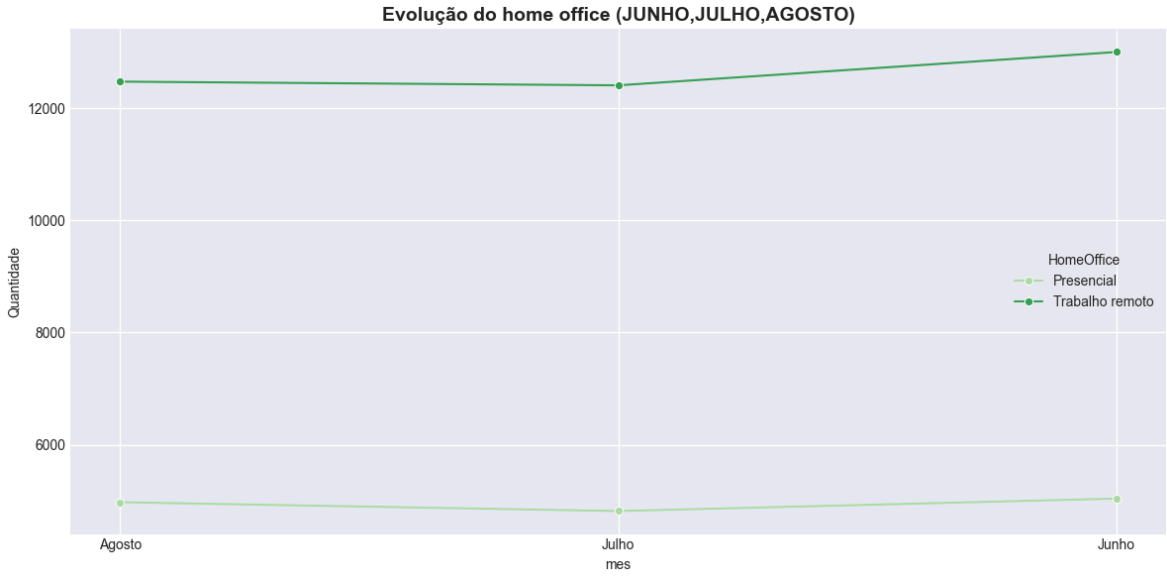

Em [38]:
```
# Renda
df_renda  =  df_f [ df_f [ "Variavel" ]  ==  "C011A12" ] . copy ()
df_renda [ "Valor" ]  =  pd . to_numeric ( df_renda [ "Valor" ],  erros = "coagi

renda_mes  =  df_renda . groupby ( "mes" )[ "Valor" ] . mediana () . índice_rese

plt . figura ( figsize = ( 10 ,  5 ))
sns . lineplot (
    dados = renda_mes ,
    x = "mes" ,
    y = "Valor" ,
    marcador = "o" ,
    cor = "roxo"
)
plt . title ( "Evolução da renda mediana (JUNHO,JULHO,AGOSTO)" ,  fontsize = 14
plt . ylabel ( "Renda mediana (R$)" )
plt . tight_layout ()
plt . mostrar ()
```

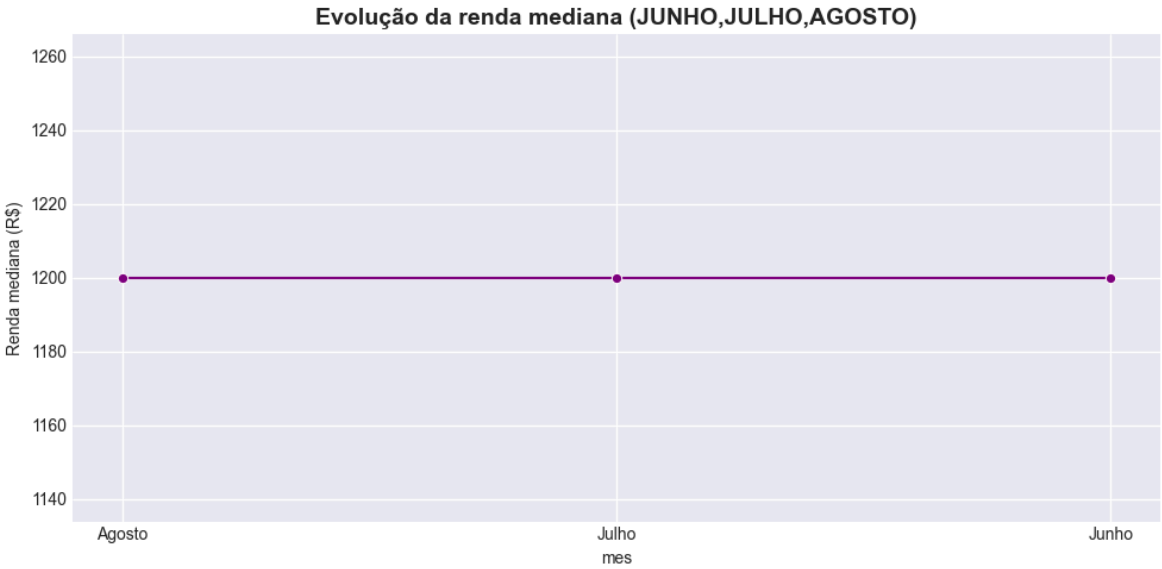

a distribuição entre trabalho, estar afastado ou não trabalhar mudou um pouco, o home office praticamente no mesmo nível e a renda mediana se manteve constante, Essas evoluções indicam o mercado de trabalho após os impactos da pandemia.